Université Paris Cité

# Vers une classification interprétable des émotions faciales

DAN SEBAG
GASPARD LUGAT
MEHDI BENAYED
DIMITRI DERAMOND

*Avril 2026*

Université Paris Cité

## Table des matières


1. Introduction ..... 3
2. Contexte et Etat de l'art ..... 4
   - 2.1 Reconnaissance d'émotions faciales ..... 4
   - 2.2 Architectures CNN pour la reconnaissance d'émotions ..... 4
   - 2.3 Interprétabilité des modèles (Explainable AI) ..... 5
   - 2.4. Données utilisées pour l'apprentissage ..... 5
   - 2.5. Prétraitement des données ..... 5
   - 2.6. Architecture du modèle GIMEFIVE ..... 6
   - 2.7. Fonction de sortie et fonction de perte ..... 6
   - 2.8. Entraînement et optimisation ..... 6
   - 2.9. Synthèse ..... 7
3. Reproduction et Analyse des résultats ..... 8
   - 3.1. Présentation des modèles évalués ..... 8
   - 3.2. Entraînement ..... 8
   - 3.3. Les résultats ..... 9
   - 3.4. Interprétation des modèles ..... 10
   - 3.5. Matrice de confusion ..... 10
   - 3.6. Points méthodologiques ..... 11
4. Axes d'amélioration et limites de l'étude ..... 13
   - 4.1. Limite Scientifique et Ethique ..... 13
   - 4.2. Limites méthodologiques ..... 13
   - 4.3. Limites liées au surapprentissage ..... 13
   - 4.4. Limites liés à l'instabilité de certains modèles ..... 14
   - 4.5. Limites computationnelles ..... 14
   - 4.6. Analyse de l'espace latent : intérêt et limites de PCA/UMAP ..... 14
   - 4.7. Pistes d'amélioration sur les données ..... 15
   - 4.8. Pistes d'amélioration sur les modèles ..... 16
   - 4.9. Pistes d'amélioration sur l'évaluation ..... 16

# 1. Introduction

La reconnaissance automatique des émotions faciales (Facial Emotion Recognition, FER) constitue aujourd'hui un sous-domaine central de la vision par ordinateur, une discipline de l'intelligence artificielle qui vise à permettre aux machines de percevoir et d'analyser des images ou des vidéos. Elle consiste à identifier l'état émotionnel d'un individu à partir de son visage, en s'appuyant sur des images fixes ou des flux vidéo. Ce type d'approche est mobilisé dans de nombreux contextes, notamment pour les interactions homme-machine, l'analyse du comportement ou encore certaines applications liées à la santé et à la personnalisation des services.

Les progrès récents du deep learning, et en particulier l'utilisation des réseaux de neurones convolutionnels (CNN), ont permis d'améliorer significativement les performances des systèmes de reconnaissance d'émotions. Ces modèles sont capables d'extraire automatiquement des caractéristiques pertinentes à partir des données visuelles, sans nécessiter de conception manuelle de descripteurs. Néanmoins, malgré leur efficacité, ils présentent une limite importante, à savoir leur manque d'interprétabilité. En pratique, ils sont souvent considérés comme des « boîtes noires », ce qui rend difficile la compréhension des décisions produites et peut poser des problèmes de confiance dans certains contextes d'utilisation.

Dans ce cadre, le développement de modèles à la fois performants et interprétables constitue un enjeu majeur. Le papier *GIMEFIVE: Towards Interpretable Facial Emotion Classification* s'inscrit précisément dans cette problématique. Il propose une architecture de réseau de neurones convolutionnel dédiée à la classification des émotions faciales, tout en intégrant des mécanismes permettant d'expliquer les prédictions du modèle. Cette approche repose notamment sur l'utilisation de techniques d'Explainable AI, telles que Grad-CAM, qui permettent de visualiser les régions de l'image ayant le plus influencé la décision.

Dans la suite du rapport, nous présenterons d'abord le contexte et l'état de l'art, en détaillant les principales approches utilisées en reconnaissance d'émotions ainsi que les architectures de réseaux de neurones associées. Nous décrirons ensuite la méthodologie et les choix techniques du modèle étudié. Enfin, nous proposerons une analyse des résultats obtenus, ainsi que des pistes d'amélioration.

# 2. Contexte et Etat de l'art

## 2.1 Reconnaissance d'émotions faciales

La reconnaissance des émotions faciales à identifier automatiquement l'état émotionnel d'un individu à partir de son visage, que ce soit à partir d'images fixes ou de séquences vidéo.

Ce champ de recherche s'appuie en grande partie sur les travaux du psychologue américain Paul Ekman, qui ont mis en évidence l'existence de six émotions universelles, à savoir le bonheur, la tristesse, la colère, la peur, la surprise et le dégoût. Ces émotions sont généralement considérées comme reconnaissables indépendamment du contexte culturel, ce qui en fait une base de référence pour les systèmes de classification automatique.

Les premières méthodes reposaient sur l'extraction de caractéristiques définies manuellement, telles que la position des yeux, la forme de la bouche ou les contours du visage. Cependant, ces approches présentaient des limites importantes, notamment une faible capacité de généralisation et une forte dépendance à la qualité des descripteurs conçus par l'humain. L'essor du deep learning a renouvelé ces méthodes en permettant aux modèles d'apprendre directement des représentations à partir des données. Les CNN, en particulier, se sont imposés comme des outils très efficaces. En effet, ils sont capables de capturer les structures spatiales et les relations entre les différentes parties du visage.

## 2.2 Architectures CNN pour la reconnaissance d'émotions

Dans le cadre de la reconnaissance d'émotions, plusieurs architectures de réseaux de neurones convolutionnels sont couramment utilisées comme références pour évaluer les performances de nouveaux modèles.

Le modèle VGG repose sur une architecture profonde constituée d'une succession de couches convolutionnelles utilisant des filtres de petite taille, généralement de dimension 3×3. Cette structure permet d'augmenter la profondeur du réseau tout en conservant une organisation relativement simple. Ce modèle est ainsi capable d'apprendre des représentations visuelles complexes. Toutefois, son grand nombre de paramètres constitue un inconvénient majeur, car il entraîne un coût de calcul élevé ainsi qu'un risque accru de surapprentissage.

Afin de pallier les difficultés liées à l'entraînement de réseaux très profonds comme les problèmes de vanishing ou d'exploding gradient, l'architecture ResNet introduit le concept de connexions résiduelles. Ces connexions permettent de transmettre directement l'information entre différentes couches du réseau, facilitant ainsi la propagation du gradient lors de l'apprentissage. Ce mécanisme rend possible l'entraînement de réseaux plus profonds sans dégradation des performances. Les variantes ResNet18 et ResNet34 sont particulièrement utilisées, car elles offrent un compromis intéressant entre profondeur, efficacité et coût de calcul.

## 2.3 Interprétabilité des modèles (Explainable AI)

Malgré leurs performances élevées, les modèles de deep learning et en particulier les CNN, sont souvent perçus comme des systèmes opaques, dont les décisions restent difficiles à interpréter. Cette absence de transparence peut poser problème, notamment lorsqu'il est nécessaire de comprendre les erreurs du modèle ou de justifier ses prédictions.

Le domaine de l'Explainable AI (XAI) vise précisément à répondre à ces enjeux en développant des méthodes rendant les modèles plus interprétables. Parmi elles, Grad-CAM est couramment utilisée. Cette technique permet de visualiser les zones de l'image les plus importantes pour la décision du modèle. Elle aide ainsi à mieux comprendre sur quoi le modèle se base pour classifier les émotions. Elle est notamment utilisée dans le modèle GIMEFIVE.

## 2.4. Données utilisées pour l'apprentissage

Le modèle GIMEFIVE s'appuie sur plusieurs bases de données publiques dédiées à la reconnaissance d'émotions faciales comme RAF-DB, FER2013, AffectNet, CK+ et TFEID. Ces jeux de données regroupent des images représentant différentes expressions émotionnelles. Ils ont été collectés dans des contextes variés, allant de situations contrôlées à des environnements réels plus complexes.

Afin d'augmenter la diversité des données et d'améliorer la robustesse du modèle, ces différentes bases sont combinées pour former un dataset agrégé nommé FER GIMEFIVE. Cette approche permet d'augmenter significativement le volume de données disponibles pour l'entraînement, tout en exposant le modèle à une plus grande variété de visages et de conditions. Elle favorise ainsi une meilleure capacité de généralisation sur des données nouvelles.

## 2.5. Prétraitement des données

Avant d'être utilisées pour l'entraînement, les images subissent plusieurs étapes de prétraitement visant à homogénéiser les données et à faciliter l'apprentissage du modèle. Elles sont d'abord redimensionnées en 64×64 pixels afin de réduire la complexité de calcul tout en conservant les informations essentielles. Elles sont ensuite converties en niveaux de gris tout en conservant trois canaux, ce qui permet de respecter le format d'entrée et de simplifier l'information visuelle. Une étape de normalisation est également appliquée pour standardiser les valeurs des pixels.

Le choix de travailler en niveaux de gris repose sur l'hypothèse que la couleur n'apporte pas d'information déterminante pour la reconnaissance des émotions. En effet, les émotions faciales reposent principalement sur des caractéristiques géométriques du visage, telles que les mouvements de la bouche ou des yeux. La couleur peut varier fortement selon les conditions d'acquisition des images et introduire du bruit.

Dans le cas des vidéos, une étape supplémentaire consiste à détecter les visages dans chaque image. Cette détection est réalisée à l'aide de l'algorithme de Viola-Jones, qui permet d'identifier rapidement les régions d'intérêt. Une fois le visage extrait, les mêmes étapes de prétraitement que pour les images fixes sont appliquées.

## *2.6. Architecture du modèle GIMEFIVE*

Le modèle GIMEFIVE repose sur une architecture de réseau de neurones convolutionnel conçue pour offrir un compromis entre performance et efficacité. Il est composé de cinq blocs convolutionnels successifs. Chacun d'eux comprend une couche de convolution suivie d'une batch normalization, d'une opération de max pooling et d'un mécanisme de dropout. Cette organisation permet à la fois d'extraire des caractéristiques pertinentes et de limiter le surapprentissage.

Au fur et à mesure de la propagation dans le réseau, le nombre de filtres augmente, ce qui permet de capturer des caractéristiques de plus en plus abstraites. À l'issue de cette partie convolutionnelle, plusieurs couches fully connected sont utilisées afin de transformer les caractéristiques extraites en une prédiction finale correspondant à l'une des six émotions.

## *2.7. Fonction de sortie et fonction de perte*

La sortie du modèle est obtenue à l'aide de la fonction softmax, qui transforme les valeurs produites par le réseau en probabilités. Cette transformation permet d'interpréter directement les résultats en termes de probabilité d'appartenance à chaque classe.

L'apprentissage du modèle repose sur la fonction de perte cross-entropy, qui mesure l'écart entre les prédictions du modèle et les étiquettes réelles. Cette fonction est particulièrement adaptée aux problèmes de classification multi-classes, car elle pénalise fortement les prédictions incorrectes tout en valorisant celles qui se rapprochent des classes correctes.

## *2.8. Entraînement et optimisation*

L'entraînement du modèle GIMEFIVE repose sur l'algorithme de descente de gradient stochastique, avec un taux d'apprentissage fixé à 0.001 et un momentum de 0.9. Ce choix permet d'assurer une convergence stable tout en accélérant l'apprentissage.

Afin d'améliorer les performances et la robustesse du modèle, plusieurs techniques de régularisation sont utilisées. La batch normalization contribue à stabiliser les distributions des activations, ce qui facilite et accélère la convergence. Le dropout consiste à désactiver aléatoirement certains neurones pendant l'entraînement, ce qui permet de limiter le surapprentissage.

Des techniques d'augmentation de données ont également été testées, comme des rotations, des inversions ou des recadrages. Toutefois, leur impact s'est révélé limité dans ce contexte, en raison du fait que les images sont déjà alignées et normalisées. Cela montre que ll'efficacité de ces techniques dépend fortement de la nature des données utilisées.

## *2.9. Synthèse*

L'état de l'art en reconnaissance d'émotions faciales met en évidence le rôle central des réseaux de neurones convolutionnels, qui permettent d'atteindre des performances élevées tout en automatisant l'extraction de caractéristiques. Par ailleurs, les enjeux liés à l'interprétabilité des modèles occupent une place croissante, notamment avec l'utilisation de méthodes telles que Grad-CAM. Le modèle GIMEFIVE s'inscrit dans cette dynamique en proposant une architecture à la fois performante, relativement compacte et interprétable, répondant ainsi aux principales problématiques du domaine.

# 3. Reproduction et Analyse des résultats

## 3.1. Présentation des modèles évalués

Dans le cadre de cette reproduction, cinq modèles ont été entraînés et évalués sur le dataset FER GIMEFIVE : le modèle original GiveMeFive, qui est le modèle que l'on veut comparer avec les autres afin de vérifier si il est meilleur pour évaluer les émotions faciales.

Le deuxième modèle, une variante du premier, GiveMeFiveRes, introduit des connexions résiduelles. L'idée est de faciliter la propagation du gradient et de rendre l'optimisation plus stable, surtout lorsque le réseau devient plus profond.

Le troisième modèle ResNet18, correspond à une architecture résiduelle plus standard et plus profonde. Il s'agit d'un modèle plus puissant, utilisé ici comme point de comparaison pour évaluer si une augmentation importante de la capacité du réseau se traduit effectivement par un gain sur la tâche de reconnaissance des émotions.

ResNet34, est sensiblement identique, mais pousse encore davantage cette logique en augmentant la profondeur du réseau. L'hypothèse testée est vraiment de vérifier si une architecture plus profonde peut mieux capturer les variations complexes des expressions faciales, ou bien finit-elle par compliquer l'entraînement sans apport décisif en généralisation.

Enfin, le cinquième modèle, VGG, représente une autre famille de CNN plus classiques, fondée sur des convolutions empilées de manière régulière. Ce modèle est intéressant car il permet de comparer une approche plus basique à des architectures résiduelles plus modernes. Il sert donc de point de repère supplémentaire pour étudier le rapport entre profondeur, stabilité d'apprentissage et performance finale.

## 3.2. Entraînement

L'entraînement est lui aussi bien construit. La fonction de coût utilisée est une CrossEntropyLoss avec label_smoothing=0.05, ce qui aide à éviter un modèle trop confiant et améliore souvent la généralisation.
L'optimiseur est AdamW, adapté à un entraînement stable avec régularisation via le weight_decay. ReduceLROnPlateau réduit automatiquement le taux d'apprentissage quand la validation n'améliore plus, et l'early stopping permet d'arrêter l'entraînement lorsque les gains deviennent négligeables. C'est pourquoi tous les modèles n'ont pas le même nombre d'époches.

Notre but est donc de contrôler ce qui se passe dans l'apprentissage de nos modèles, et surtout d'être attentif au risque du surapprentissage, souvent très fréquent dans notre contexte.

## 3.3. Les résultats

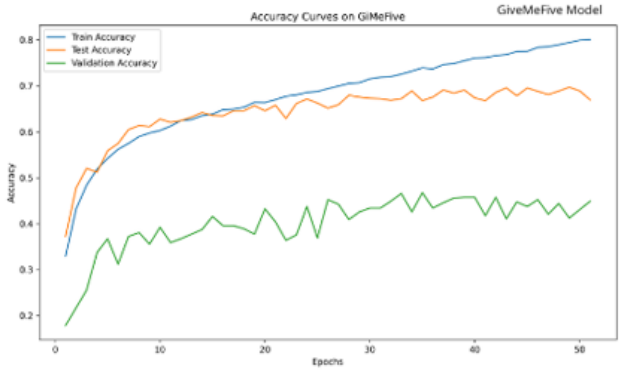


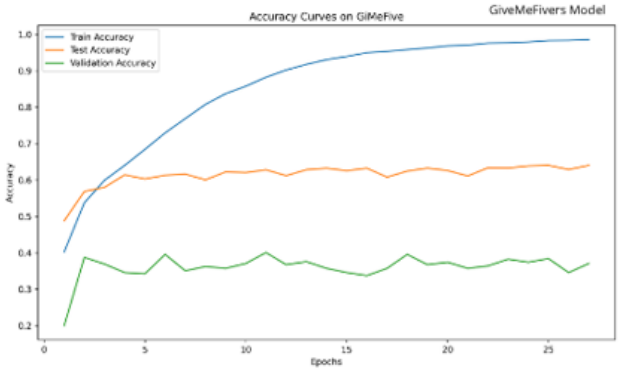


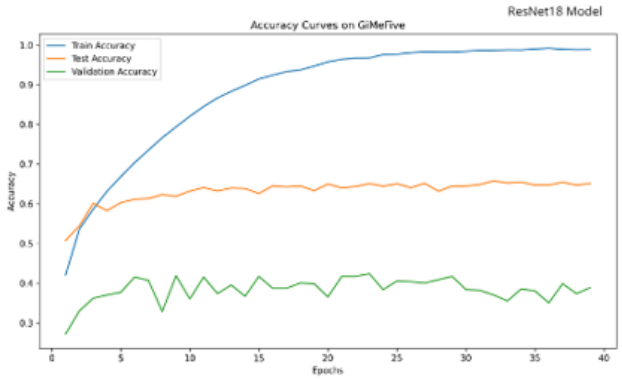


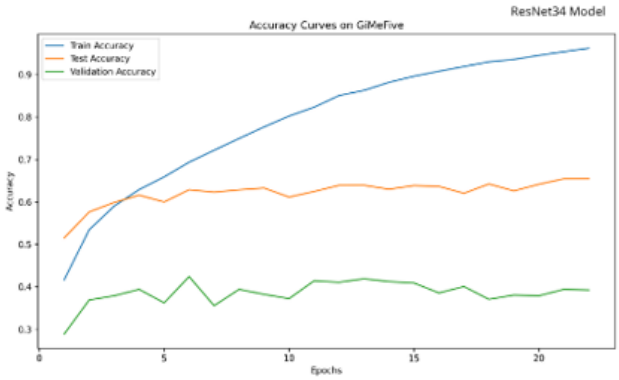


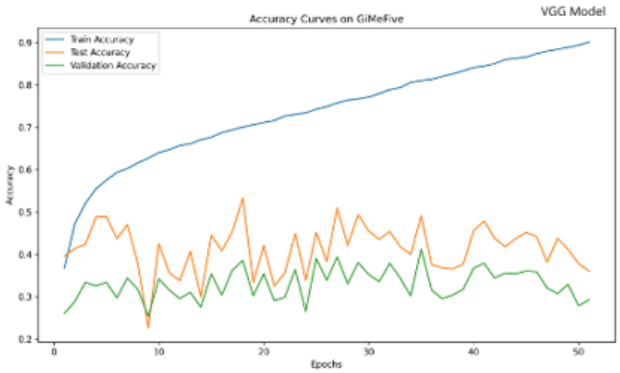


GiveMeFive présente le comportement le plus équilibré parmi les cinq modèles. La courbe d'entraînement monte progressivement jusqu'à environ 0,85, tandis que l'accuracy de test se stabilise autour de 0,70. L'écart entre ces deux courbes reste modéré et la progression est stable sur l'ensemble des époques. Ce modèle présente donc un certain niveau de surapprentissage, mais celui-ci reste contenu, ce qui témoigne d'une capacité de généralisation raisonnable.

GiveMeFivers montre en revanche un comportement nettement différent. La train accuracy atteint 1,0 très rapidement, en quelques époques seulement, tandis que les courbes de test et de validation plafonnent respectivement autour de 0,65 et 0,37. Cet écart très prononcé entre la performance sur les données d'entraînement et celle sur les données non vues indique un surapprentissage sévère. Le modèle mémorise les données d'entraînement plutôt qu'il n'en extrait des représentations généralisables.

ResNet18 et ResNet34 présentent des comportements quasi similaires, tous deux caractérisés par un surapprentissage marqué. Dans les deux cas, la train accuracy converge vers 1,0 tandis que la test accuracy plafonne autour de 0,65 et la validation accuracy autour de 0,38. Ces résultats sont contre-intuitifs au premier abord, dans la mesure où les architectures résiduelles sont réputées pour leur capacité à bien généraliser. Cependant, ils s'expliquent probablement par le fait que ces modèles, conçus pour des tâches à très grande échelle, se révèlent surdimensionnés pour ce jeu de données. Leur capacité d'expression élevée leur permet d'ajuster parfaitement les données d'entraînement, au détriment de la généralisation.

VGG constitue le cas le plus problématique. Bien que la train accuracy progresse jusqu'à environ 0,90, les courbes de test et de validation sont extrêmement instables tout au long de l'entraînement, oscillant entre 0,20 et 0,55 sans jamais se stabiliser. Ce comportement chaotique suggère que l'optimisation est difficile à conduire sur ce dataset, possiblement en raison du très grand nombre de paramètres de l'architecture VGG, qui la rend particulièrement sensible à la configuration d'entraînement. VGG est sans conteste le modèle le moins adapté à cette tâche dans ce contexte.

## *3.4. Interprétation des modèles*

L’interprétation modèle par modèle est assez nette.

À la lecture de ces courbes, GiveMeFive ressort comme le modèle le plus performant en termes de généralisation, avec une test accuracy d'environ 0,70 et une dynamique d'apprentissage stable. C'est également le seul modèle dont la courbe de validation reste dans une plage raisonnable, même si un écart significatif subsiste avec la train accuracy.

Les autres modèles, qu'il s'agisse de GiveMeFivers, ResNet18, ResNet34 ou VGG, présentent tous des limitations importantes. GiveMeFivers et les deux variantes ResNet souffrent d'un surapprentissage prononcé, tandis que VGG se distingue par une instabilité persistante. Ces résultats mettent en évidence que des architectures plus complexes ou plus profondes ne garantissent pas de meilleures performances de généralisation, en particulier lorsque les données disponibles restent limitées en volume ou en diversité.

## *3.5. Matrice de confusion*

La matrice de confusion permet ensuite d’aller au-delà de l’accuracy globale. Elle montre quelles émotions sont bien reconnues et lesquelles sont le plus souvent confondues. Dans notre cas, la surprise semble très bien reconnue, disgust est correcte, tandis que fear, sad et anger restent plus difficiles à prédire.

Cela s’explique bien dans une tâche de reconnaissance faciale : certaines émotions ont des signatures visuelles nettes, alors que d’autres se confondent davantage.

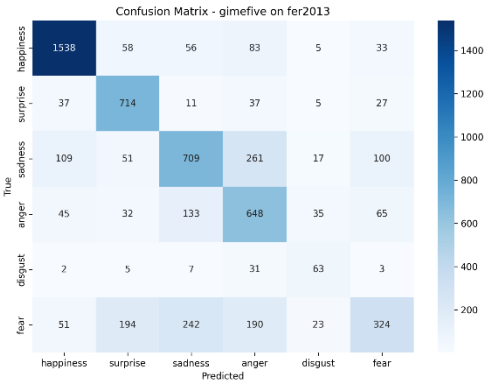


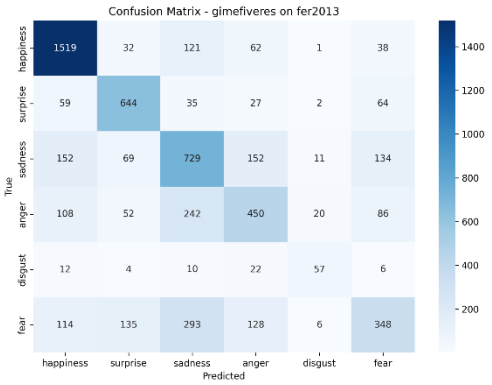


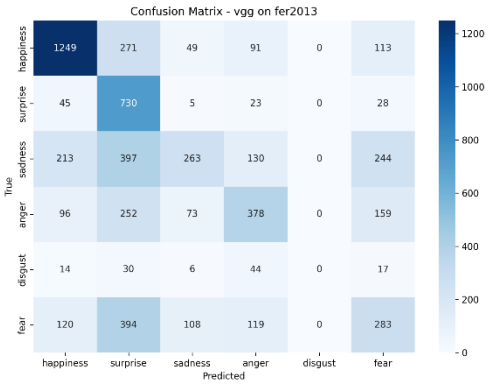


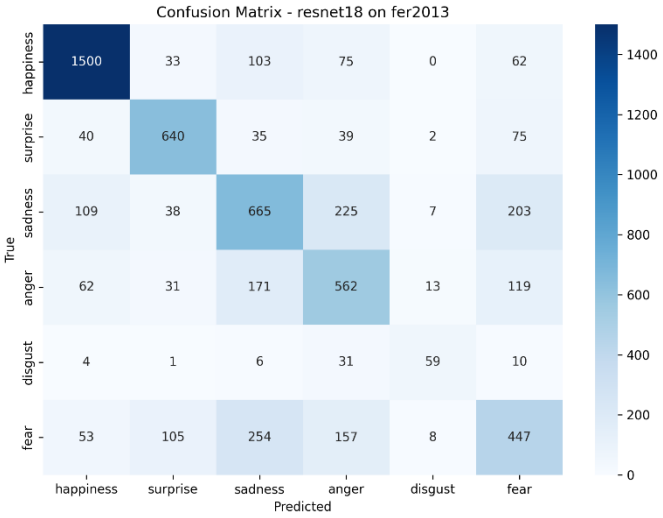


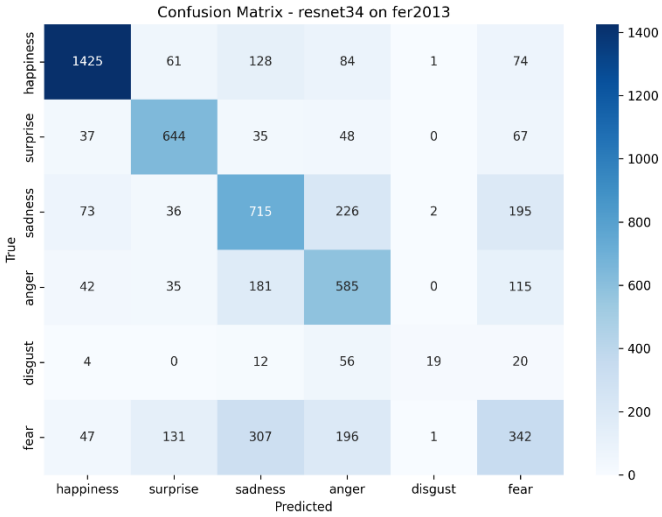


Les matrices de confusion confirment très nettement les tendances observées dans la partie 3.3. Pour les modèles les plus performants, les prédictions se concentrent davantage sur la diagonale, ce qui signifie que les classes sont mieux reconnues, même si certaines émotions restent encore régulièrement confondues entre elles. À l'inverse, les modèles dont les courbes d'apprentissage montraient un comportement plus instable présentent aussi des matrices plus dispersées, avec davantage d'erreurs entre classes proches.

## *3.6. Points méthodologiques*

Ces résultats soulèvent plusieurs observations importantes. Premièrement, la complexité architecturale n'est pas corrélée positivement avec la performance de généralisation dans ce contexte. GiveMeFive, qui est une architecture spécifiquement conçue et calibrée pour cette tâche, surpasse les modèles plus lourds sur cet aspect. Deuxièmement, le surapprentissage constitue un défi commun à presque tous les modèles testés, ce qui suggère que les mécanismes de régularisation mis en place, à savoir dropout, batch normalization, ne suffisent pas toujours à compenser la capacité excessive de certaines architectures face à la taille du dataset.

Par ailleurs, l'écart important et persistant entre accuracy de validation et accuracy de test, observé sur tous les modèles, mérite d'être noté. Il peut s'expliquer par des différences de distribution entre les splits du dataset, ou par le fait que la sélection de checkpoint sur la validation favorise des configurations sous-optimales pour le test.

Enfin, ces résultats confirment l'intérêt de l'approche proposée par GIMEFIVE : concevoir une architecture compacte et adaptée à la tâche, plutôt que de simplement transposer des modèles généralistes développés pour d'autres contextes. La spécificité architecturale apparaît comme un facteur déterminant pour obtenir un bon compromis entre performance et généralisation dans le domaine de la reconnaissance d'émotions faciales.

# 4. Axes d'amélioration et limites de l'étude

## 4.1. Limite Scientifique et Ethique

La première limite concerne la nature même du problème. La reconnaissance des émotions faciales est une tâche intrinsèquement difficile, car les expressions sont parfois proches, ambiguës ou influencées par le contexte. De plus, les émotions faciales ne se manifestent pas toujours de la même manière. En effet, leur interprétation peut varier selon les personnes, les cultures et les situations.

Cette limite est importante sur le plan scientifique comme sur le plan éthique. Elle rappelle que les résultats d'un modèle de classification doivent être utilisés avec prudence, surtout lorsqu'ils nous concernent, humains. L'étude a donc une valeur expérimentale forte, mais elle ne doit pas être surinterprétée ni sortie de son contexte.

## 4.2. Limites méthodologiques

Une limite importante tient au protocole d'évaluation. Sur l'ensemble des modèles testés, on observe un écart systématique et prononcé entre la validation accuracy et la test accuracy : la première est presque toujours bien inférieure à la seconde. Cet écart, particulièrement visible sur GiveMeFivers, ResNet18 et ResNet34 où la validation accuracy plafonne autour de 0,37–0,38 pendant que la test accuracy atteint 0,65, montre une différence dans la répartition des données entre les différents splits. C'est pourquoi il serait utile de contrôler plus finement la constitution des ensembles de train, validation et test, par exemple via une validation croisée, afin de s'assurer que les conclusions tirées des courbes d'apprentissage sont robustes.

## 4.3. Limites liées au surapprentissage

Les courbes d'apprentissage révèlent un surapprentissage prononcé pour la majorité des modèles évalués. GiveMeFivers, ResNet18 et ResNet34 atteignent tous une train accuracy proche de 1,0 en quelques époques, tandis que leurs performances sur les données de test stagnent à des niveaux inférieurs. Ce phénomène indique que ces architectures, dont la capacité d'expression est élevée, finissent par mémoriser les exemples d'entraînement plutôt qu'à en extraire des représentations généralisables à d'autres jeux de données inconnus.

Même GiveMeFive, qui présente le comportement le plus équilibré, n'échappe pas totalement à ce phénomène, car l'écart entre train et test accuracy reste notable avec beaucoup d'époches. Cela suggère que la capacité des modèles dépasse ce que la taille et la diversité du dataset permettent d'exploiter pleinement. Les mécanismes de régularisation que nous avons mis en place tels que dropout, batch normalization, early stopping, scheduler, contribuent à contenir ce phénomène, mais ne suffisent pas à l'éliminer. C'est donc un problème persistant dans l'interprétation des émotions faciales.

## 4.4. Limites liés à l'instabilité de certains modèles

Nous avons également relevé une limite sur le cas de VGG, qui est l'instabilité de l'optimisation. Les courbes de test et de validation de ce modèle oscillent de manière chaotique tout au long de l'entraînement, sans jamais converger vers un comportement stable. Cette instabilité rend les résultats de VGG difficilement exploitables et confirme que des architectures très lourdes, initialement conçues pour des tâches à grande échelle, ne sont pas nécessairement adaptées à un dataset de cette nature. Ce constat nous a donc fait comprendre l'importance d'adapter le choix de l'architecture aux contraintes spécifiques du problème traité.

## 4.5. Limites computationnelles

Enfin, des contraintes techniques ont également pesé sur le déroulement des expériences. L'entraînement de modèles tels que ResNet ou VGG est coûteux en temps et en ressources, ce qui limite le nombre de configurations testables et la reproductibilité dans des environnements de calcul restreints. Cette contrainte est d'autant plus significative si l'on envisage une utilisation en conditions réelles ou en temps réel, pour laquelle des modèles compacts comme GiveMeFive présentent un avantage pratique non négligeable, ce qui en fait pour toutes ces raisons le meilleur modèle.

## 4.6. Analyse de l'espace latent : intérêt et limites de PCA/UMAP

L'étude des représentations internes du modèle apporte un éclairage complémentaire aux résultats de classification. Pour cela, nous avons projeté les features extraites par le réseau dans un espace de dimension réduite à l'aide de deux méthodes : PCA et UMAP. Le graphique ci-dessous montre ces projections pour ResNet18, en colorant les points selon les vraies classes d'émotions.

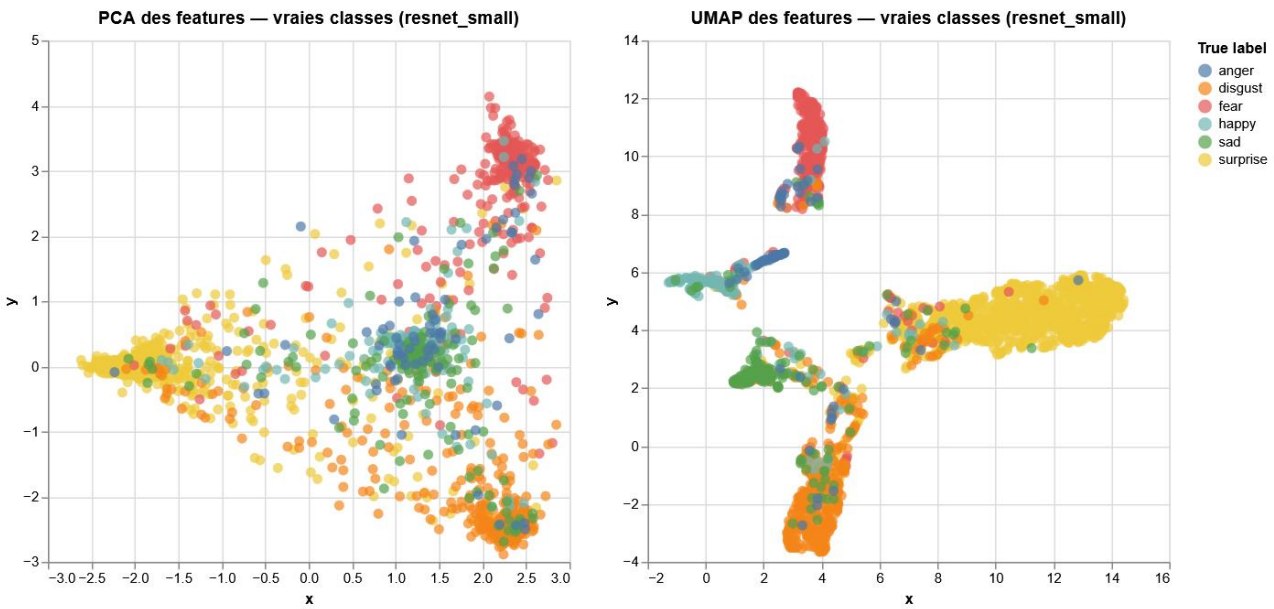

La projection PCA offre une première vision globale de la structure des données. Elle permet d'observer que certaines émotions occupent des régions distinctes de l'espace latent, mais elle met aussi en évidence des zones de recouvrement importantes entre plusieurs classes. Cela signifie que, même si le modèle apprend une structure discriminante, cette séparation n'est pas parfaite dans l'espace linéaire résumé par les deux premières composantes principales.

UMAP donne une lecture plus fine et plus locale de ces représentations. Sur le graphique, on observe des amas beaucoup plus nets, avec certaines émotions qui forment des groupes compacts et relativement bien séparés. En particulier, certaines classes apparaissent plus faciles à distinguer visuellement comme par exemple la peur ou la surprise, tandis que d'autres restent proches les unes des autres (par exemple la joie ou la tristesse). Cette observation rejoint l'analyse de la matrice de confusion, où certaines émotions sont effectivement plus souvent confondues que d'autres.

Ces projections permettent de mieux comprendre le comportement du modèle, mais elles ne suffisent pas à elles seules pour conclure définitivement sur la séparabilité réelle des classes.

Dans le cadre de cette étude, PCA et UMAP permettent de vérifier que le réseau a bien appris des représentations organisées, et de repérer les classes les plus proches dans l'espace latent. En ce sens, ils constituent davantage un outil d'analyse et de compréhension qu'un levier direct d'amélioration du modèle. C'est pourquoi nous pensons qu' ils n'étaient pas présents dans l'étude initiale que nous avons reprise, mais nous pensons que cela permet d'améliorer l'interopérabilité de l'étude.

## *4.7. Pistes d'amélioration sur les données*

Un autre axe d'amélioration consisterait à enrichir le jeu de données. Ajouter davantage d'images, diversifier les profils, équilibrer les classes et intégrer des conditions de prise de vue plus variées permettrait d'améliorer la robustesse du modèle. Cette démarche réduirait aussi les biais liés à certaines émotions sous-représentées.

Il serait également intéressant de tester des augmentations de données plus riches, comme des variations de luminosité, de contraste, de rotation légère ou de recadrage. Le random horizontal flip constitue une première étape utile, mais il reste relativement simple. Des transformations plus variées permettraient d'exposer le réseau à des situations plus proches du réel.

C'est pourquoi nous avons décidé de tester ces 5 modèles sur un jeu de données extérieur que nous avons trouvé en faisant des recherches. Le souci est que ce sont des données pour le grand public, et que tout est un peu mélangé. Il n'y a pas uniquement des visages, mais aussi parfois des corps entiers. Comme nous pouvions le prévoir, les résultats n'étaient pas aussi bons que sur le jeu de données fer2013 utilisé pour apprendre les modèles :

## 4.8. Pistes d'amélioration sur les modèles

Concernant l'architecture, les résultats montrent que l'attention SE n'apporte pas un gain systématique. Cela ne signifie pas que ce mécanisme est inutile, mais plutôt qu'il ne s'impose pas comme une amélioration automatique dans ce cadre expérimental.

À l'inverse, les connexions résiduelles semblent apporter une contribution plus claire. Il serait donc pertinent d'explorer d'autres variantes de réseaux résiduels, ou de tester des architectures préentraînées plus adaptées à la reconnaissance visuelle. Le transfert d'apprentissage pourrait notamment permettre de bénéficier de représentations déjà robustes, tout en réduisant le besoin d'un apprentissage complet à partir de zéro.

## 4.9. Pistes d'amélioration sur l'évaluation

Une analyse plus poussée des erreurs permettrait aussi d'identifier les classes les plus difficiles et de comprendre si certaines émotions sont systématiquement confondues entre elles. Ce type d'information est très utile pour orienter les prochaines améliorations du modèle. Il permet de passer d'une lecture purement quantitative à une compréhension plus qualitative du comportement du réseau.

# 5. Conclusion

En conclusion, cette étude reproduit et analyse plusieurs modèles de reconnaissance d'émotions faciales afin de mieux comprendre leurs performances et surtout comprendre leur comportement interne.

L'étude a permis de montrer qu'un modèle plus complexe n'est pas nécessairement meilleur dans tous les cas : certaines architectures plus légères, comme le modèle de base, obtiennent de meilleurs résultats que ceux d'un réseau plus profond, ce qui souligne l'importance du compromis entre performance et coût de calcul.

Les expériences menées ont également mis en évidence que les connexions résiduelles apportent un gain réel en stabilisant l'apprentissage et en améliorant légèrement la généralisation. En revanche, l'ajout de mécanismes d'attention de type SE n'a pas produit d'amélioration systématique dans notre configuration expérimentale. Cette observation rappelle qu'une architecture plus sophistiquée n'entraîne pas automatiquement de meilleurs résultats, et qu'il est nécessaire d'évaluer chaque composant dans un cadre de benchmark rigoureux.

Au-delà des scores globaux, l'analyse des courbes d'apprentissage, de la matrice de confusion et des projections PCA/UMAP a permis de mieux comprendre le comportement interne du modèle. Ces outils ont montré que certaines émotions sont mieux séparées que d'autres dans l'espace latent, tandis que certaines classes restent plus facilement confondues, ce qui confirme la difficulté intrinsèque de la tâche. L'étude ne se limite donc pas à une simple comparaison d'accuracy, mais apporte aussi une lecture plus fine de la manière dont le réseau représente les émotions faciales, et c'est le point sur lequel nous voulions arriver.

Enfin, ce travail met en évidence plusieurs limites, notamment le risque de surapprentissage, la sensibilité au découpage des données et les contraintes liées à la qualité du jeu de données. Ces limites ouvrent la voie à plusieurs améliorations possibles, comme un enrichissement du corpus, une augmentation plus poussée des données, une évaluation plus détaillée par classe, ou encore le test de modèles préentraînés plus robustes. En ce sens, ce projet constitue une base solide pour de futurs travaux sur la reconnaissance automatique des émotions faciales, en montrant à la fois les apports des CNN, tout en essayant de surmonter les difficultés déjà rencontrées.